PROPOSTA DI RICERCA SPERIMENTALE

PINN-CANON

Dall’“inconsistenza della natura” all’inconsistenza del modello

Uso di una Physics-Informed Neural Network per identificare diffusività termica, dispersioni e limiti delle assunzioni di uniformità e costanza

Campo	Definizione
Area	Fisica computazionale · termodinamica · scientific machine learning
Forma	Progetto individuale di ricerca riproducibile
Durata	12–16 settimane
Livello	Scuola secondaria avanzata / primo anno universitario
Risultato	Esperimento, dataset, codice, confronto tra modelli e paper finale

Principio guida. Una misura che non coincide con una legge non dimostra che la natura sia incoerente: può rivelare un parametro variabile, una condizione al contorno ignorata, un errore sperimentale o un modello incompleto.

Documento operativo in italiano · Edizione 2026

Abstract

Il progetto PINN-CANON trasforma una riflessione filosofica sui presupposti della fisica in un'indagine sperimentale quantitativa. Il sistema studiato è la conduzione termica transitoria in una barra metallica. Una serie di sensori misura la temperatura in posizioni differenti durante cicli di riscaldamento e raffreddamento. I dati vengono analizzati con modelli fisici progressivamente più complessi e con una Physics-Informed Neural Network (PINN), cioè una rete neurale addestrata non soltanto a interpolare le misure, ma anche a rispettare un'equazione differenziale. Il problema inverso consiste nello stimare la diffusività termica e le dispersioni verso l'ambiente, verificando se l'ipotesi di parametri uniformi e costanti sia sufficiente.

Il valore scientifico non risiede nel "dimostrare" che una costante fisica cambi. Risiede nel costruire un protocollo capace di distinguere quattro spiegazioni concorrenti: materiale non uniforme, proprietà dipendenti dalla temperatura, condizioni al contorno mal modellate ed errore di misura. Il progetto prevede un confronto obbligatorio con un metodo numerico classico e con una rete neurale puramente data-driven, una validazione su esperimenti mai mostrati in addestramento, analisi di sensibilità, ablation study e pubblicazione riproducibile di dati e codice. Il risultato è un lavoro credibile di fisica computazionale, adatto a mostrare autonomia, rigore e capacità interdisciplinare in una candidatura universitaria.

Parole chiave: PINN; equazione del calore; problema inverso; diffusività termica; identificabilità; modellazione; riproducibilità.

STATO DEL LAVORO	Questo documento è una proposta di ricerca completa, non un articolo con risultati già ottenuti. Tabelle e grafici di risultato dovranno essere prodotti dallo studente con dati reali; non devono essere simulati o inventati.

Indice

Abstract 2

Indice 3

1. Origine e trasformazione della domanda 5

1.1 Perché scegliere il calore . . . 5

1.2 Obiettivo generale . . . 5

1.3 Domanda di ricerca . . . 5

2. Ipotesi e criteri di falsificazione 5

2.1 Ipotesi operative . . . 6

2.2 Che cosa renderebbe il progetto scientificamente riuscito . . . 6

3. Fondamenti fisici 6

3.1 Legge di Fourier e bilancio energetico . . . 6

3.2 Modello ridotto . . . 6

3.3 Condizioni iniziali e al contorno . . . 7

3.4 Grandezze adimensionali . . . 7

4. Apparato sperimentale 7

4.1 Componenti minimi . . . 8

4.2 Configurazione consigliata . . . 8

4.3 Tre famiglie di prove . . . 8

5. Protocollo di misura e qualità dei dati 8

5.1 Calibrazione . . . 8

5.2 Metadati obbligatori . . . 9

5.3 Numero di repliche . . . 9

5.4 Controlli di qualità . . . 9

6. Modello PINN 9

6.1 Idea essenziale . . . 9

6.2 Residuo fisico . . . 10

6.3 Funzione obiettivo . . . 10

6.4 Architettura iniziale . . . 10

7. Confronti obbligatori 11

7.1 Metriche . . . 11

7.2 Criteri preliminari di successo . . . 11

7.3 Ablation study . . . 11

8. Piano operativo per lo studente 11

8.1 Procedura tecnica essenziale . . . 12

9. Implementazione software 12

9.1 Struttura del repository . . . 12

9.2 Pseudocodice della loss . . . 13

9.3 Test software minimi . . . 13

10. Analisi, interpretazione e limiti 13

10.1 Identificabilità . . . 13

10.2 Model discrepancy . . . 13

10.3 Failure modes delle PINN . . . 13

10.4 Freccia del tempo come estensione . . . 13

11. Sicurezza, integrità e riproducibilità 14

11.1 Sicurezza sperimentale . . . 14

11.2 Integrità scientifica . . . 14

11.3 Pacchetto riproducibile . . . 14

12. Deliverable e valore formativo 14

12.1 Elementi che distinguono il lavoro . . . 14

12.2 Estensioni possibili . . . 15

13. Checklist di completamento 15

Riferimenti 15

Nota bibliografica . . . 16

Appendice A. Scheda minima di una prova 16

Appendice B. Domande prima della conclusione 16

1. Origine e trasformazione della domanda

Il draft *L'inconsistenza della natura* parte da una domanda fertile: le regolarità attribuite alla natura sono osservazioni oppure condizioni che rendono possibile la scienza? Il testo organizza la riflessione attorno a uniformità, costanza, direzione, simmetria e conservazione. Nella forma originaria, tuttavia, il passaggio da "non possiamo dimostrare ogni evento futuro" a "la natura è plasmata dall'uomo" è troppo forte per costituire una conclusione fisica. La scienza non richiede una prova metafisica dell'eternità di una legge; formula modelli controllabili, ne specifica il dominio di validità e tenta di falsificarne le previsioni.

Il progetto conserva l'intuizione centrale, ma la rende operativa: quanto dipende la stima di una proprietà fisica dalle assunzioni usate nel modello? La domanda è affrontata su un sistema sufficientemente semplice da essere costruito da uno studente, ma abbastanza ricco da porre problemi autentici di conduzione, dissipazione, rumore e identificabilità.

RIFORMULAZIONE Non si studia l'inconsistenza della natura. Si studia la possibile inconsistenza tra dati, equazione scelta e condizioni sperimentali. Questa distinzione è il centro epistemologico e tecnico del progetto.

1.1 Perché scegliere il calore

La diffusione termica è ideale per tre ragioni. Primo, produce dati continui nello spazio e nel tempo con strumenti accessibili. Secondo, è descritta da un'equazione differenziale parabolica nota, quindi permette un confronto trasparente fra soluzione numerica e PINN. Terzo, collega direttamente uniformità e costanza dei parametri alla direzione macroscopica dei processi irreversibili: una distribuzione non uniforme di temperatura tende all'equilibrio, mentre la ricostruzione retrograda dello stato iniziale è estremamente sensibile al rumore.

1.2 Obiettivo generale

Progettare, costruire e validare un sistema sperimentale che misuri la propagazione del calore in una barra e utilizzi una PINN per stimare proprietà e termini fisici non direttamente osservati, confrontando ipotesi alternative senza confondere variazioni del modello con variazioni della natura.

1.3 Domanda di ricerca

Una PINN addestrata su misure termiche sparse riesce a distinguere tra diffusività materiale non uniforme e dispersioni termiche spazialmente variabili, mantenendo capacità predittiva su esperimenti indipendenti?

2. Ipotesi e criteri di falsificazione

L'esperimento non deve essere organizzato per confermare una tesi preferita. Deve rendere confrontabili spiegazioni concorrenti. Le ipotesi seguenti sono formulate in modo che ciascuna possa fallire.

Modello	Ipotesi fisica	Indicatore di fallimento
M0	Diffusività α costante; dispersione h uniforme.	Errore sistematico localizzato; residui correlati con posizione o temperatura.
M1	Diffusività α(x) variabile; h uniforme.	α(x) instabile fra repliche o compensazione artificiale delle perdite laterali.
M2	Diffusività α costante; dispersione h(x) variabile.	Residui persistenti anche dopo aver modellato la zona non isolata.

Modello	Ipotesi fisica	Indicatore di fallimento
M3	α(T) dipende dalla temperatura; h uniforme o noto.	Mancato miglioramento su prove tenute fuori dall'addestramento.
M4	Modello congiunto α(x,T) e h(x).	Non identificabilità: soluzioni diverse spiegano gli stessi dati.

Il modello più complesso non è automaticamente il migliore. Sarà preferito soltanto se migliora la previsione su intere prove sperimentali non viste e se i parametri rimangono stabili rispetto a inizializzazione, rumore e posizione dei sensori. In caso contrario, l'aumento di complessità sarà interpretato come overfitting o non identificabilità.

2.1 Ipotesi operative

- H1. Nel setup uniforme e ben isolato, M0 dovrebbe fornire una descrizione adeguata entro l'incertezza sperimentale.
- H2. Una perdita termica localizzata dovrebbe essere rilevata più correttamente da M2 che da M1.
- H3. Se si forza M1 su dati generati da perdite variabili, la rete potrebbe attribuire falsamente al materiale una diffusività spaziale non uniforme.
- H4. La validazione su prove indipendenti e l'analisi dei residui dovrebbero distinguere, almeno parzialmente, queste spiegazioni.
- H5. La ricostruzione all'indietro della temperatura sarà meno stabile della previsione in avanti, specialmente dopo l'aggiunta di rumore.

2.2 Che cosa renderebbe il progetto scientificamente riuscito

Un risultato negativo è accettabile. Se la PINN non riesce a separare α(x) e h(x), il progetto avrà comunque identificato un limite di informazione del setup. Il successo consiste nel dimostrare con dati, controlli e analisi perché una conclusione è o non è giustificata.

3. Fondamenti fisici

3.1 Legge di Fourier e bilancio energetico

In una barra sottile, assumendo temperatura quasi uniforme sulla sezione, il flusso termico longitudinale è descritto dalla legge di Fourier. Se k è la conducibilità termica e T la temperatura, il flusso per unità di area è:

$$q(x,t) = -k(x,T) \cdot \partial T(x,t)/\partial x$$

Applicando la conservazione dell'energia a un elemento infinitesimo della barra e includendo lo scambio convettivo con l'ambiente, si ottiene un modello monodimensionale:

$$\rho c_p A \cdot \partial T/\partial t = \partial/\partial x \left[kA \cdot \partial T/\partial x \right] - hP(T - T_{amb}) + Q_{src}(x,t)$$

Qui ρ è la densità, c_p il calore specifico, A l'area della sezione, P il perimetro esposto, h il coefficiente efficace di scambio con l'ambiente e Q una sorgente distribuita. Il termine con h è essenziale: se viene ignorato, la rete può compensare la fisica mancante alterando la proprietà che si desidera stimare.

3.2 Modello ridotto

Nel caso ideale di materiale omogeneo, area costante, assenza di sorgenti interne e perdite laterali trascurabili, si introduce la diffusività termica $\alpha = k/(\rho c_p)$ e l'equazione diventa:

$$\partial T/\partial t - \alpha \cdot \partial^2 T/\partial x^2 = 0$$

Questa forma è utile per la fase sintetica e come baseline, ma non deve essere adottata automaticamente per l'esperimento reale. La sua adeguatezza sarà precisamente l'oggetto della verifica.

3.3 Condizioni iniziali e al contorno

Per definire il problema servono la temperatura iniziale T(x,0) e le condizioni alle estremità. L'estremità riscaldata può essere descritta mediante temperatura imposta o flusso noto; l'estremità opposta mediante isolamento approssimato oppure convezione. Poiché il flusso reale del riscaldatore è difficile da conoscere con precisione, una versione avanzata del progetto può trattarlo come funzione incognita $q_{in}(t)$ da stimare.

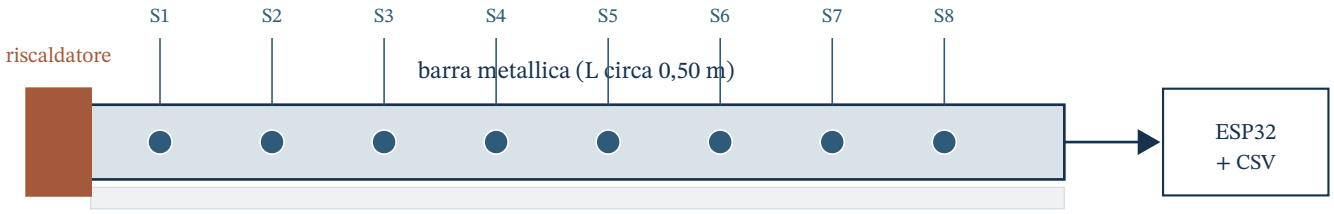
3.4 Grandezze adimensionali

Il numero di Fourier $Fo = \alpha t/L^2$ confronta il tempo trascorso con il tempo caratteristico di diffusione. Il numero di Biot, nella geometria appropriata, confronta la resistenza interna alla conduzione con quella superficiale allo scambio. Questi numeri aiutano a scegliere durata della prova, spaziatura dei sensori e validità dell'approssimazione monodimensionale.

CONTROLLO DIMENSIONALE	Ogni equazione implementata deve essere verificata nelle unità SI. Prima dell'addestramento, x e t possono essere normalizzati, ma la trasformazione deve essere documentata perché modifica le derivate calcolate dalla rete.

4. Apparato sperimentale

L'apparato deve essere semplice, ripetibile e sicuro. Una configurazione consigliata utilizza una barra di alluminio lunga circa 0,50 m, con sezione rettangolare costante, riscaldata a bassa tensione a un'estremità. Otto sensori vengono fissati a distanze note; un ulteriore sensore misura l'aria ambiente. La barra poggia su materiale isolante e viene schermata dalle correnti d'aria, salvo nelle prove in cui la dispersione viene modificata intenzionalmente.



isolamento controllato; temperatura ambiente misurata

Figura 1. Schema funzionale dell'apparato. Le dimensioni definitive devono essere misurate e riportate con relativa incertezza.

4.1 Componenti minimi

Componente	Funzione	Nota di progetto
Barra metallica	Dominio fisico 1D.	Misurare L, larghezza, spessore e massa.
Riscaldatore DC	Fornisce un ingresso ripetibile.	Alimentazione isolata; nessuna parte di rete esposta.
8–10 sensori	Campionano T(x,t).	Calibrazione individuale e contatto termico controllato.
Sensore ambiente	Misura T_amb(t).	Tenere distante dal riscaldatore.
ESP32/Arduino	Acquisizione e timestamp.	Salvataggio CSV con frequenza nota.
Isolamento e supporti	Riduzione delle perdite.	Geometria documentata con fotografie.
Ventola piccola	Perturbazione controllata.	Usata soltanto nelle prove di stress.

4.2 Configurazione consigliata

- Lunghezza utile: 0,40–0,60 m; sezione costante e misurata con calibro.
- Otto sensori distribuiti lungo l’asse, con maggiore densità vicino alla sorgente.
- Campionamento iniziale: 1 misura al secondo; riducibile dopo verifica dei tempi caratteristici.
- Ciclo tipo: 10 min di equilibrio, 35–50 min di riscaldamento, 45–60 min di raffreddamento.
- Temperatura superficiale massima consigliata: 55–60 °C, sotto supervisione.

4.3 Tre famiglie di prove

1. Baseline. Barra uniformemente isolata; potenza e ambiente il più possibile costanti.
2. Perdita localizzata. Rimuovere l’isolamento in una regione nota oppure applicare un piccolo dissipatore passivo.
3. Convezione variabile. Applicare un flusso d’aria controllato su una regione, mantenendo invariato il materiale.

Questa scelta genera un test importante: la proprietà materiale non cambia, ma un modello incompleto potrebbe interpretare la diversa dispersione come variazione di diffusività. Il progetto misura quindi la capacità della PINN di evitare una conclusione fisica sbagliata.

5. Protocollo di misura e qualità dei dati

5.1 Calibrazione

Prima di montare i sensori, registrarli insieme in almeno due bagni a temperatura stabile, confrontandoli con un termometro di riferimento. Per ciascun sensore stimare offset, eventuale correzione lineare e deviazione standard. La calibrazione deve essere conservata come file separato e applicata con uno script, non manualmente.

5.2 Metadati obbligatori

Campo	Esempio	Perché serve
run_id	B03	Separa repliche e impedisce leakage fra train e test.
time_s	125.0	Asse temporale con unità esplicita.
sensor_id / x_m	S4 / 0.210	Posizione fisica e tracciabilità.
temperature_C	31.42	Misura corretta dalla calibrazione.
ambient_C	22.18	Condizione al contorno variabile.
heater_state	on / 24 W	Ingresso del sistema.
configuration	uniform / local_loss	Definisce il protocollo.
notes	ventola spostata a 800 s	Documenta anomalie e interventi.

5.3 Numero di repliche

Eseguire almeno cinque repliche per la baseline e tre per ogni perturbazione. Un'intera replica deve essere riservata come test finale e non utilizzata durante la scelta del modello. Se il tempo lo consente, ripetere alcune prove in giorni differenti: non per verificare metafisicamente la costanza della natura, ma per quantificare la robustezza rispetto a condizioni reali non perfettamente controllate.

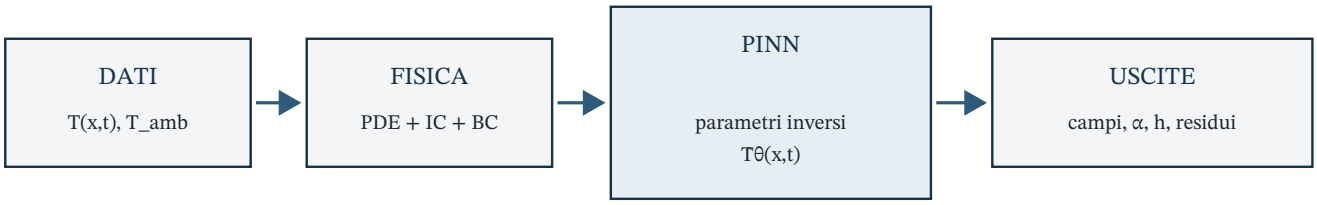
5.4 Controlli di qualità

- Controllare timestamp mancanti, duplicati, saturazioni e salti non fisici.
- Visualizzare ogni serie prima del training; non eliminare outlier senza una regola documentata.
- Propagare l'incertezza di posizione e temperatura almeno tramite analisi di sensibilità.
- Conservare dati grezzi immutabili e dati processati in cartelle diverse.
- Versionare codice, configurazioni e seed casuali.

6. Modello PINN

6.1 Idea essenziale

Una rete neurale $T_\theta(x,t)$ riceve posizione e tempo e restituisce la temperatura prevista. Grazie alla differenziazione automatica è possibile calcolare la derivata temporale e la derivata spaziale seconda della temperatura prevista. Queste derivate entrano nel residuo dell'equazione fisica. La rete viene quindi penalizzata sia quando non coincide con i sensori sia quando viola il modello imposto.



L'ottimizzazione riduce insieme errore sui dati e violazione delle leggi imposte

Figura 2. Flusso logico della PINN: dati e vincoli fisici contribuiscono congiuntamente all'ottimizzazione.

6.2 Residuo fisico

Per il modello ridotto con diffusività costante, il residuo è:

$$r_\theta(x,t) = \partial T_\theta/\partial t - \alpha \cdot \partial^2 T_\theta/\partial x^2$$

Per il modello con perdite laterali, può essere scritto in forma normalizzata come:

$$r_\theta = \partial T/\partial t - \partial/\partial x\,[\,\alpha(x,T) \cdot \partial T/\partial x\,] + \beta(x)(T - T_{amb}) - s(x,t)$$

Il parametro β raccoglie geometricamente ed energeticamente lo scambio con l'ambiente; *s* descrive la sorgente. La parametrizzazione deve essere collegata all'equazione dimensionale originale per evitare coefficienti privi di interpretazione.

6.3 Funzione obiettivo

$$\mathcal{L} = \lambda_d \mathcal{L}_{dati} + \lambda_f \mathcal{L}_{PDE} + \lambda_{ic} \mathcal{L}_{iniziale} + \lambda_{bc} \mathcal{L}_{bordi} + \lambda_r \mathcal{L}_{reg}$$

I pesi λ non devono essere scelti per rendere gradevole una curva. Devono essere registrati, sottoposti ad analisi di sensibilità e, se possibile, bilanciati in base alle scale o ai gradienti dei diversi termini. La regolarizzazione impedisce a funzioni come α(x) o β(x) di oscillare senza giustificazione sperimentale.

6.4 Architettura iniziale

Elemento	Scelta iniziale	Motivazione
Input	x e t normalizzati in [−1,1]	Migliora il condizionamento numerico.
Rete T	4–5 layer, 64 neuroni, tanh	Baseline comune, derivabile e sufficientemente espressiva.
Output	Temperatura normalizzata	Scala numerica controllata.
Parametri inversi	α e β positivi via softplus	Vincolo fisico senza clipping.
Collocation points	5.000–20.000	Campionamento del dominio spazio-temporale.
Ottimizzazione	Adam, poi L-BFGS	Esplorazione iniziale e rifinitura.
Repliche numeriche	Almeno 5 seed	Misura della stabilità dell'ottimizzazione.

REGOLA	La rete non deve vedere il test finale. Le suddivisioni vanno effettuate per intera prova sperimentale, non estraendo casualmente punti dalla stessa curva.

7. Confronti obbligatori

Una PINN isolata non è una dimostrazione. Per rendere il lavoro credibile, deve essere confrontata con metodi che separino il contributo della fisica dal contributo della rete.

Baseline	Scopo	Domanda
Soluzione analitica semplificata	Sanity check su casi ideali.	Il codice riproduce un caso noto?
Differenze finite	Riferimento numerico classico.	La PINN offre accuratezza comparabile?
Fit parametrico classico	Stima diretta di α e h.	La rete è davvero necessaria?
MLP data-driven	Rete senza termine fisico.	La PDE migliora generalizzazione e data efficiency?
PINN M0–M4	Confronto delle ipotesi.	Quale fisica spiega meglio prove indipendenti?

7.1 Metriche

- RMSE e MAE della temperatura sulle prove tenute fuori.
- Errore relativo L^2 sul dataset sintetico, dove la soluzione di riferimento è nota.
- Residuo fisico normalizzato in punti non usati come collocation points.
- Stabilità dei parametri fra seed, repliche e configurazioni.
- Copertura dell'incertezza tramite ensemble o bootstrap delle prove.
- Costo computazionale e tempo di addestramento rispetto al solver classico.

7.2 Criteri preliminari di successo

Gli obiettivi numerici sono target, non risultati garantiti: errore relativo inferiore al 2% sul caso sintetico pulito; RMSE inferiore a 1 °C su almeno una prova reale non vista; stima di α stabile entro il 10–15% fra seed nel setup baseline; identificazione corretta della regione di perdita in M2; degradazione documentata quando rumore, sensori o condizioni al contorno vengono alterati.

7.3 Ablation study

Rimuovere a turno dati, residuo PDE, condizioni al contorno e regolarizzazione. Se le prestazioni non cambiano, quel termine non sta contribuendo oppure è implementato male. Ripetere inoltre l'analisi con 2, 4, 6 e 8 sensori per misurare quanta informazione sia realmente necessaria.

8. Piano operativo per lo studente

Il progetto è diviso in fasi con un prodotto verificabile. Non si passa alla fase successiva finché il controllo della precedente non è superato.

Settimane	Attività	Prodotto verificabile
1–2	Studio della conduzione 1D, Python e differenziazione automatica.	Notebook con soluzione analitica e controllo unità.
3	Solver a differenze finite e generazione dati sintetici.	Dataset sintetico con rumore controllato.
4–5	PINN forward sul caso α noto.	Confronto PINN–FDM e grafici di errore.
6	PINN inversa per α costante.	Recupero del parametro su dati sintetici.

Settimane	Attività	Prodotto verificabile
7	Costruzione apparato e calibrazione.	Schema, fotografie, file calibrazione, valutazione sicurezza.
8–9	Raccolta baseline e perturbazioni.	CSV grezzi, metadati e log di laboratorio.
10–11	Training M0–M3 e baseline classiche.	Tabella comparativa su test indipendente.
12	Stress test, ablation e incertezza.	Analisi di sensibilità e failure cases.
13–14	Scrittura, revisione, repository e poster.	Paper finale, README riproducibile, presentazione.
15–16	Estensione opzionale e revisione esterna.	Feedback di docente/ricercatore e versione 2.

8.1 Procedura tecnica essenziale

1. Derivare il modello e verificare unità e condizioni al contorno.
2. Generare dati sintetici con un solver indipendente dalla PINN.
3. Addestrare la PINN forward e verificare che ricostruisca T(x,t).
4. Rendere α addestrabile e verificarne il recupero su dati noti.
5. Calibrare e montare l'apparato; acquisire almeno una prova pilota.
6. Definire train, validation e test per intere repliche.
7. Confrontare M0, M1, M2 e M3; non introdurre M4 finché i modelli semplici non sono compresi.
8. Eseguire analisi dei residui, seed multipli, bootstrap e ablation.
9. Scrivere prima i limiti e poi le conclusioni.

9. Implementazione software

L'implementazione può essere realizzata con PyTorch o con una libreria dedicata come DeepXDE. Per un progetto di candidatura è consigliabile comprendere e implementare almeno una versione minima direttamente in PyTorch; una libreria può essere usata successivamente come verifica indipendente.

9.1 Struttura del repository

```
pinn-canon/
|-- data/
|   |-- raw/              # dati immutabili
|   |-- calibration/      # coefficienti dei sensori
|   `-- processed/        # dataset pronto per il training
|-- configs/              # geometria, loss weights, seed
|-- src/
|   |-- physics.py        # PDE, IC, BC e unita
|   |-- fdm.py            # baseline numerica
|   |-- pinn.py           # rete e derivate automatiche
|   |-- train.py
|   `-- evaluate.py
|-- notebooks/            # esplorazione, non logica finale
|-- tests/                # casi analitici e controlli
|-- results/              # figure generate da script
|-- environment.yml
|-- README.md
`-- LICENSE
```

9.2 Pseudocodice della loss

```
# x_f, t_f: punti di collocazione nel dominio
T_hat = network(x_f, t_f)
T_t   = grad(T_hat, t_f)
T_x   = grad(T_hat, x_f)
T_xx  = grad(T_x, x_f)

alpha = positive(raw_alpha)
beta  = positive(raw_beta)
residual = T_t - alpha*T_xx + beta*(T_hat - T_ambient)

loss = (
    lambda_data * mse(T_pred_at_sensors, T_measured)
  + lambda_pde  * mse(residual, 0)
  + lambda_ic   * mse(T_initial_pred, T_initial)
  + lambda_bc   * boundary_loss
  + lambda_reg  * parameter_smoothness
)
```

9.3 Test software minimi

- La derivata automatica di una funzione nota coincide con la derivata analitica.
- Il solver FDM converge riducendo passo spaziale e temporale.
- La PINN recupera α su dati sintetici senza rumore.
- Il risultato è riproducibile fissando seed e configurazione.
- L'intero pipeline rigenera le figure senza modifiche manuali.

10. Analisi, interpretazione e limiti

10.1 Identificabilità

Il problema più importante non è la potenza della rete, ma l'identificabilità: differenti combinazioni di α, h e flusso in ingresso possono produrre curve di temperatura simili. Se i sensori sono pochi o collocati male, la PINN può trovare una soluzione numericamente ottima ma fisicamente ambigua. Per questo sono necessari perturbazioni controllate, repliche, prior fisici, regolarizzazione e confronto con misure indipendenti.

10.2 Model discrepancy

La barra reale non è perfettamente monodimensionale; il contatto fra sensore e metallo introduce ritardo; la conducibilità può dipendere dalla temperatura; radiazione e convezione non sono sempre lineari. Il residuo della PINN non rappresenta quindi soltanto errore della rete: contiene anche l'inadeguatezza dell'equazione.

10.3 Failure modes delle PINN

Le PINN possono soffrire di ottimizzazione mal condizionata e sbilanciamento dei gradienti tra i termini della loss. Un residuo PDE basso non garantisce una soluzione corretta se condizioni iniziali e dati sono soddisfatti male. Il progetto deve mostrare curve separate delle componenti di loss, risultati per seed multipli e confronto con il solver classico.

10.4 Freccia del tempo come estensione

Dopo aver validato il modello forward, si può tentare di ricostruire T(x,0) a partire da dati finali rumorosi. L'equazione del calore smorza rapidamente le componenti spaziali ad alta frequenza; invertirla amplifica il rumore. L'esperimento rende concreta l'asimmetria informativa tra previsione e ricostruzione, senza sostenere che le equazioni microscopiche siano semplicemente "indimostrabili".

CONCLUSIONE AMMESSA	“Con questi dati e questo modello, l’ipotesi X è meglio supportata dell’ipotesi Y” è una conclusione scientifica. “La natura non è costante” non lo è.

11. Sicurezza, integrità e riproducibilità

11.1 Sicurezza sperimentale

- Usare esclusivamente riscaldamento a bassa tensione con alimentatore protetto.
- Fissare una soglia di spegnimento automatico e non lasciare il sistema incustodito.
- Proteggere parti calde, usare supporti non infiammabili e attendere il raffreddamento.
- Far verificare collegamenti elettrici e protocollo da un docente o adulto competente.
- Registrare incidenti, modifiche e anomalie nel log di laboratorio.

11.2 Integrità scientifica

- Non eliminare prove fallite: classificarle e spiegare perché non sono utilizzabili.
- Non scegliere iperparametri sul test finale.
- Non presentare dati sintetici come misure reali.
- Indicare dipendenze software, versioni, hardware e tempo di calcolo.
- Pubblicare anche configurazioni che hanno fallito, quando informative.

11.3 Pacchetto riproducibile

Il repository finale deve contenere dati grezzi, script di calibrazione, configurazioni, codice di training, test, ambiente software e un comando unico per rigenerare le figure principali. Ogni risultato del paper deve essere riconducibile a un file e a una configurazione.

12. Deliverable e valore formativo

Deliverable	Contenuto	Evidenza di qualità
Paper di ricerca	Domanda, teoria, metodo, risultati, limiti.	Conclusioni proporzionate ai dati.
Repository pubblico	Codice, test, configurazioni e licenza.	Esecuzione riproducibile.
Dataset versionato	Misure grezze, calibrazione e metadati.	Provenienza completa.
Poster tecnico	Sistema, equazioni, confronto e risultati.	Comunicazione sintetica.
Video di 3–5 min	Apparato e spiegazione del metodo.	Capacità divulgativa.
Diario di ricerca	Decisioni, errori, revisioni e feedback.	Autonomia e maturità.

Il progetto è competitivo non perché utilizza una parola di moda, ma perché integra filosofia della scienza, derivazione fisica, costruzione sperimentale, modellazione numerica, machine learning, analisi critica e comunicazione aperta. Le università selettive valutano soprattutto la qualità del ragionamento e la prova di iniziativa; nessun progetto garantisce l’ammissione, ma un lavoro eseguito con rigore può fornire materiale concreto per portfolio, colloquio e lettera di raccomandazione.

12.1 Elementi che distinguono il lavoro

- La PINN affronta un vero problema inverso, non una semplice classificazione.
- L’esperimento include perturbazioni progettate per ingannare un modello incompleto.

- Sono previsti baseline classiche e risultati negativi.
- La tesi filosofica viene trasformata in una domanda falsificabile.
- Il prodotto finale è riproducibile e sottoponibile a revisione esterna.

12.2 Estensioni possibili

- Piastra 2D osservata con termocamera e confronto con il modello 1D.
- Bayesian PINN o ensemble calibrato per quantificare l'incertezza.
- Optimal sensor placement per massimizzare l'identificabilità.
- Scoperta di termini mancanti mediante sparse regression o universal differential equations.
- Confronto fra PINN, finite elements e neural operator su più geometrie.

13. Checklist di completamento

Verifica	Criterio di accettazione
Fisica	Equazioni derivate, unità controllate, ipotesi dichiarate.
Esperimento	Calibrazione, repliche, test indipendente e sicurezza documentati.
Dati	Raw immutabili, metadati completi, trasformazioni scriptate.
PINN	Loss separata, seed multipli, collocation documentata.
Baseline	Confronto con FDM, fit classico e MLP data-driven.
Validazione	Nessun leakage; metriche su intere prove non viste.
Incertezza	Sensibilità a rumore, sensori, pesi e inizializzazione.
Interpretazione	Nessuna equivalenza impropria fra parametro appreso e verità fisica.
Riproducibilità	README e comando per rigenerare risultati.
Comunicazione	Paper, figure, repository e presentazione coerenti.

DECISIONE FINALE — Il progetto è pronto per essere presentato quando una persona esterna riesce a ricostruire almeno una figura principale partendo dal repository e quando il test finale non è mai stato usato per scegliere il modello.

Riferimenti

[1] Masci, *L'inconsistenza della natura*, appunti inediti e bozza di lavoro, documento fornito come origine concettuale del progetto.

[2] M. Raissi, P. Perdikaris, G. E. Karniadakis, "Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations", *Journal of Computational Physics*, 378, 686–707, 2019. DOI: 10.1016/j.jcp.2018.10.045.

[3] G. E. Karniadakis et al., "Physics-informed machine learning", *Nature Reviews Physics*, 3, 422–440, 2021. DOI: 10.1038/s42254-021-00314-5.

[4] L. Lu, X. Meng, Z. Mao, G. E. Karniadakis, "DeepXDE: A deep learning library for solving differential equations", *SIAM Review*, 63(1), 208–228, 2021. DOI: 10.1137/19M1274067.

[5] A. S. Krishnapriyan, A. Gholami, S. Zhe, R. M. Kirby, M. W. Mahoney, "Characterizing possible failure modes in physics-informed neural networks", *Advances in Neural Information Processing Systems 34*, 2021.

[6] S. Wang, Y. Teng, P. Perdikaris, "Understanding and mitigating gradient flow pathologies in physics-informed neural networks", *SIAM Journal on Scientific Computing*, 43, A3055–A3081, 2021. DOI: 10.1137/20M1318043.

[7] J. V. Beck, B. Blackwell, C. R. St. Clair Jr., *Inverse Heat Conduction: Ill-Posed Problems*, Wiley, 1985.

[8] J. Cai et al., “Physics-Informed Neural Networks for Heat Transfer Problems”, *Journal of Heat Transfer*, 143, 2021. DOI: 10.1115/1.4050542.

Nota bibliografica

I riferimenti [2]–[6] definiscono il quadro metodologico e i principali limiti delle PINN. Il riferimento [7] inquadra la natura mal posta dei problemi inversi di conduzione; [8] documenta applicazioni delle PINN a problemi di trasferimento termico. Nella versione finale del paper sperimentale, ogni scelta specifica di sensore, materiale e algoritmo dovrà essere accompagnata dalla relativa scheda tecnica o fonte.

Appendice A. Scheda minima di una prova

Voce	Contenuto da registrare
Identificazione	run_id, data, operatore, configurazione e commit del codice.
Geometria	Dimensioni della barra, posizioni dei sensori e fotografie.
Calibrazione	Versione del file e coefficienti applicati.
Condizioni iniziali	Temperatura della barra e dell’ambiente prima dell’avvio.
Ingresso	Tensione, corrente, potenza o segnale di controllo nel tempo.
Eventi	Accensione, spegnimento, ventola, spostamenti e anomalie.
Esito	File prodotti, sensori esclusi e motivazione dell’eventuale esclusione.

Appendice B. Domande prima della conclusione

- Il modello è stato valutato su una prova mai usata per scegliere architettura o pesi?
- Un solver classico o un fit parametrico spiega i dati altrettanto bene?
- Il parametro appreso è stabile cambiando seed, rumore e numero di sensori?
- Esiste una spiegazione alternativa basata sulle condizioni al contorno?
- La conclusione distingue chiaramente osservazione, inferenza e speculazione?